Documentação do Modelo de Dados (v2)

Base de Saúde Feminina (LivWell) • Guia para as Seções 4 (Diagrama ER) e 5 (Diagrama relacional)

Este documento descreve o modelo de dados atual, que é exatamente o banco criado pela Seção 3 do `TP_IBD.ipynb`. Ele traz tudo o que é preciso para desenhar o **diagrama ER** (Seção 4) e o **diagrama relacional** (Seção 5) e para escrever os textos dessas seções.

0. O que precisa ser entregue

Seção do notebook	Conteúdo esperado
4. Diagrama ER	Imagem do diagrama ER (notação de Chen) salva em `diagramas/er.png` e um texto curto explicando entidades, relacionamentos e cardinalidades (ver checklist na Parte A).
5. Diagrama relacional	Imagem do esquema relacional salva em `diagramas/relacional.png` e o esquema em texto, com chaves primárias e estrangeiras (ver Parte B).

Para exibir a imagem no notebook, use uma célula Markdown com `![Diagrama ER](diagramas/er.png)` e `![Diagrama relacional](diagramas/relacional.png)`.

Ferramentas sugeridas: brModelo (tem notação de Chen nativa, incluindo entidade fraca, e gera o modelo lógico) ou draw.io / diagrams.net (formas "Entity Relation"). Exportar em PNG.

Requisitos do enunciado e como o modelo os cumpre

Requisito	Como o modelo atende
Pelo menos 4 tipos de entidade, cada um com ≥ 2 atributos além do identificador	5 entidades. País, Pesquisa, CategoriaIndicador e Indicador têm 2 ou mais atributos. Região tem o nome e a chave parcial (ver nota sobre Região na Parte A).
Pelo menos 3 tipos de relacionamento, ≥ 1 com cardinalidade M:N	5 relacionamentos, sendo 2 M:N: ColetaPesquisaRegiao (M:N) e Medição (ternário M:N:P).

Parte A: Diagrama ER (notação de Chen)

A.1 Símbolos a usar

Elemento	Símbolo	Onde aparece neste modelo
Entidade (forte)	Retângulo	País, Pesquisa, Indicador, CategoriaIndicador
Entidade fraca	Retângulo duplo	Região
Relacionamento	Losango	Realizada_em, ColetaPesquisaRegiao, Medição, Pertence
Relacionamento identificador	Losango duplo	Localizada_em (liga Região a País)
Atributo	Elipse ligada à entidade/relacionamento	Todos os atributos
Identificador (chave)	Nome do atributo sublinhado	country_code, SurveyId, indicator_code, category_id
Chave parcial (entidade fraca)	Nome sublinhado tracejado	region_num_harmonized (em Região)
Atributo derivado	Elipse tracejada	CMC_interview_mean em Pesquisa
Participação total	Linha dupla entre entidade e losango	Ver tabela de relacionamentos (A.3)
Cardinalidade	1, N, M, P escritos junto à linha, do lado da entidade	Ver tabela de relacionamentos (A.3)

Atenção: no ER não se desenham chaves estrangeiras. As ligações entre entidades são representadas só pelos losangos. Por isso `country_code` não aparece como atributo de Pesquisa nem de Região no ER, e `category_id` não aparece em Indicador.

A.2 Entidades e atributos

Entidade	Tipo	Identificador	Demais atributos
País	Forte	country_code	country_name, continent
Região	Fraca (depende de País)	region_num_harmonized (chave parcial)	region_name_harmonized
Pesquisa	Forte	SurveyId	year, CMC_interview_mean (**derivado**: elipse tracejada)
Indicador	Forte	indicator_code	indicator_description, indicator_type
CategoriaIndicador	Forte	category_id	category_name, category_name_pt, category_area

> **Por que Região é fraca:** `region_num_harmonized` sozinho não identifica uma região: a região 1 existe no Peru, na África do Sul, no Quênia etc. Uma região só é identificada pelo par (país, número da região). Ela "pega emprestada" a chave de País pelo relacionamento identificador Localizada_em. País é forte, porque `country_code` o identifica sozinho.

> **Por que CMC_interview_mean é derivado em Pesquisa:** a data média da entrevista varia por região dentro da mesma pesquisa. O valor "real" fica em ColetaPesquisaRegiao; em Pesquisa ele é a média das regiões (calculado).

> **Ponto que o professor pode questionar:** fora do identificador, Região só tem `region_name_harmonized`. Ela chega a 2 atributos se a chave parcial for contada como atributo. Mesmo que não seja, o requisito ("pelo menos 4 entidades" com ≥ 2 atributos) continua cumprido pelas outras 4 entidades.

A.3 Relacionamentos

Relacionamento (losango)	Liga	Cardinalidade (escrever junto a cada entidade)	Participação (linha dupla = total)	Atributos do relacionamento
Localizada_em *losango duplo (identificador)*	Região — País	Região: **N** · País: **1**	Região: **total** (dupla) País: simples	—
Realizada_em	Pesquisa — País	Pesquisa: **N** · País: **1**	Pesquisa: **total** (dupla) País: simples	—
ColetaPesquisaRegiao	Pesquisa — Região	Pesquisa: **M** · Região: **N**	Pesquisa: **total** (dupla) Região: **total** (dupla)	interview_year_mean, interview_month_mean, CMC_interview_mean
Medição *ternário*	Pesquisa — Região — Indicador	Pesquisa: **M** · Região: **N** · Indicador: **P**	as três: simples	value, standard_error
Pertence	Indicador — CategoriaIndicador	Indicador: **N** · CategoriaIndicador: **1**	Indicador: **total** (dupla) CategoriaIndicador: simples	—

Como ler as cardinalidades (todas confirmadas nos dados):

- **Localizada_em:** cada região pertence a um único país; cada país tem várias regiões (de 3 a 27).
- **Realizada_em:** cada pesquisa é de um único país; cada país tem várias pesquisas (de 2 a 11).
- **ColetaPesquisaRegiao (M:N):** uma pesquisa cobre várias regiões (de 3 a 27); uma região aparece em várias pesquisas ao longo dos anos (até 11). São 1.832 pares pesquisa × região, um por linha do CSV original.
- **Medição (M:N:P):** as letras diferentes indicam que os três lados são "muitos" e independentes: um par (pesquisa, região) tem vários indicadores medidos; um par (pesquisa, indicador) é medido em várias regiões; um par (região, indicador) aparece em várias pesquisas. Cada trio pesquisa × região × indicador tem no máximo um valor.
- **Pertence:** cada indicador pertence a uma única categoria; cada categoria tem de 1 a 13 indicadores.

A.4 Sugestão de disposição no desenho

Disposição que evita cruzamento de linhas (5 colunas × 3 linhas):

	Coluna 1	Coluna 2	Coluna 3	Coluna 4	Coluna 5
Topo	CategoriaIndicador		Pesquisa	◇ Realizada_em	
Meio	◇ Pertence (entre CategoriaIndicador e Indicador) Indicador (abaixo)	◇ Medição	◇ ColetaPesquisaRegiao		País
Base			Região (retângulo duplo)	◇◇ Localizada_em	

- **Medição** fica entre Indicador (à esquerda), Pesquisa (acima, à direita) e Região (abaixo, à direita), com uma linha para cada um.
- **ColetaPesquisaRegiao** fica numa linha vertical entre Pesquisa (em cima) e Região (embaixo), com seus 3 atributos à direita.
- **Realizada_em** liga Pesquisa a País, e **Localizada_em** liga Região a País.
- Os atributos `value` e `standard_error` ficam acima do losango Medição; os de cada entidade, ao redor dela.

A.5 Checklist do texto da Seção 4

- Dizer que foi usada a notação de Chen e o que significam os símbolos especiais usados (retângulo duplo, losango duplo, chave parcial, atributo derivado, linha dupla).
- Tabela de entidades (identificador e atributos) e tabela de relacionamentos (entidades, cardinalidade, atributos), como em A.2 e A.3.
- Explicar por que Região é entidade fraca.
- Explicar ColetaPesquisaRegiao (por que as datas de entrevista são atributos do relacionamento) e o significado de M:N:P em Medição.
- Fechar mostrando que os requisitos do enunciado foram atendidos (5 entidades, 5 relacionamentos, 2 M:N).

Parte B: Diagrama relacional

B.1 Como o ER vira tabelas (regras de mapeamento aplicadas)

Elemento do ER	Regra	Resultado
Entidades fortes (País, Pesquisa, Indicador, CategoriaIndicador)	Cada uma vira uma tabela com seus atributos; o identificador vira PK.	Pais, Pesquisa, Indicador, CategoriaIndicador
Entidade fraca Região	Vira tabela; a PK é a PK do dono (País) + a chave parcial.	Regiao, com PK (country_code, region_num_harmonized)
Relacionamentos 1:N (Localizada_em, Realizada_em, Pertence)	Não viram tabela: a PK do lado "1" vira FK no lado "N".	country_code em Regiao e em Pesquisa; category_id em Indicador
Relacionamento M:N ColetaPesquisaRegiao	Vira tabela própria; PK = PKs das duas entidades; atributos do relacionamento vão junto.	ColetaPesquisaRegiao
Relacionamento ternário Medição	Vira tabela própria com FK para as três entidades e seus atributos.	Medicao (com chave substituta `measurement_id`; a chave natural virou `UNIQUE`)
Atributo derivado CMC_interview_mean (Pesquisa)	Mantido como coluna, por conveniência nas consultas.	coluna em Pesquisa

Nos nomes das tabelas e colunas não se usam acentos (**Pais**, **Regiao**, **Medicao**), exatamente como estão no banco.

B.2 Esquema relacional completo

Convenção sugerida para o desenho e para o texto: PK sublinhada, FK em *itálico*, e no desenho uma seta saindo da FK e apontando para a PK referenciada.

```
Pais(country_code, country_name, continent)

Regiao(country_code, region_num_harmonized, region_name_harmonized)
   country_code → Pais(country_code)

Pesquisa(SurveyId, country_code, year, CMC_interview_mean)
   country_code → Pais(country_code)
   UNIQUE (SurveyId, country_code)   -- necessário para a FK composta de ColetaPesquisaRegiao

ColetaPesquisaRegiao(SurveyId, country_code, region_num_harmonized,
                     interview_year_mean, interview_month_mean, CMC_interview_mean)
   (SurveyId, country_code)              → Pesquisa(SurveyId, country_code)
   (country_code, region_num_harmonized) → Regiao(country_code, region_num_harmonized)

CategoriaIndicador(category_id, category_name, category_name_pt, category_area)
   UNIQUE (category_name)

Indicador(indicator_code, indicator_description, indicator_type, category_id)
   category_id → CategoriaIndicador(category_id)

Medicao(measurement_id, SurveyId, country_code, region_num_harmonized, indicator_code,
        value, standard_error)
   SurveyId                              → Pesquisa(SurveyId)
   (country_code, region_num_harmonized) → Regiao(country_code, region_num_harmonized)
   indicator_code                        → Indicador(indicator_code)
   UNIQUE (SurveyId, country_code, region_num_harmonized, indicator_code)
```

B.3 Setas do diagrama (8 chaves estrangeiras)

#	De (tabela.coluna)	Para (tabela.coluna)	Observação
1	Regiao.country_code	Pais.country_code	também faz parte da PK de Regiao
2	Pesquisa.country_code	Pais.country_code	
3	ColetaPesquisaRegiao.(SurveyId, country_code)	Pesquisa.(SurveyId, country_code)	FK composta: garante que a região é do mesmo país da pesquisa
4	ColetaPesquisaRegiao.(country_code, region_num_harmonized)	Regiao.(country_code, region_num_harmonized)	FK composta
5	Medicao.SurveyId	Pesquisa.SurveyId	
6	Medicao.(country_code, region_num_harmonized)	Regiao.(country_code, region_num_harmonized)	FK composta
7	Medicao.indicator_code	Indicador.indicator_code	
8	Indicador.category_id	CategoriaIndicador.category_id	

Disposição sugerida (3 colunas, setas sempre da direita para a esquerda): coluna 1 com Pais (em cima) e CategoriaIndicador (embaixo); coluna 2 com Regiao, Pesquisa e Indicador; coluna 3 com ColetaPesquisaRegiao (em cima) e Medicao (embaixo).

B.4 Checklist do texto da Seção 5

- Imagem do diagrama relacional.
- Esquema em texto (B.2), com a convenção de PK sublinhada e FK em itálico.
- Uma frase explicando que Medicao usa a chave substituta `measurement_id` e que a chave natural (pesquisa, região, indicador) é garantida por `UNIQUE`.

Parte C: Dicionário de dados

Detalhes de cada tabela do banco, com as quantidades de registros.

C.1 Pais (52 registros)

Campo	Significado
`country_code`	Código do país (ISO 3166-1 alfa-3). **PK**
`country_name`	Nome do país
`continent`	Continente (África, América ou Ásia), atribuído pelo grupo (o dataset não tem essa informação). Turquia e Armênia, transcontinentais, foram classificadas na Ásia.

C.2 Regiao (481 registros)

Campo	Significado
`country_code`	País ao qual a região pertence. **PK, FK** → Pais
`region_num_harmonized`	Número da região dentro do país (chave parcial). **PK**
`region_name_harmonized`	Nome padronizado da região

> **Ajuste nos dados:** duas regiões tinham grafias diferentes entre pesquisas (`Hauncavelica/Huancavelica` no Peru e `Western Cape/Western Cape` na África do Sul). Foi mantida a grafia da pesquisa mais recente.

C.3 Pesquisa (199 registros)

Campo	Significado
`SurveyId`	Identificador único da pesquisa DHS (ex.: `AM2000DHS`). **PK**
`country_code`	País onde a pesquisa foi realizada. **FK** → Pais
`year`	Ano da pesquisa
`CMC_interview_mean`	Data média da entrevista em CMC (Century Month Code). Derivado: média das regiões em ColetaPesquisaRegiao.

C.4 ColetaPesquisaRegiao (1.832 registros)

Campo	Significado
`SurveyId`	Pesquisa. **PK, FK** (composta com country_code) → Pesquisa
`country_code`	País. **PK, FK** (participa das duas FKs compostas)
`region_num_harmonized`	Região coberta. **PK, FK** (composta com country_code) → Regiao
`interview_year_mean`	Ano médio das entrevistas na região
`interview_month_mean`	Mês médio das entrevistas na região
`CMC_interview_mean`	Data média das entrevistas na região, em CMC

C.5 CategoriaIndicador (16 registros)

Campo	Significado
`category_id`	Identificador da categoria. **PK**
`category_name`	Nome original da categoria (ex.: Education, Nutrition). **UNIQUE**
`category_name_pt`	Nome da categoria em português
`category_area`	Área temática definida pelo grupo, que agrupa as 16 categorias em 6: Saúde reprodutiva; Saúde infantil e nutrição; Autonomia e violência; Educação e trabalho; Domicílio e condições de vida; Demografia

C.6 Indicador (100 registros)

Campo	Significado
`indicator_code`	Código do indicador. **PK**
`indicator_description`	Descrição do que o indicador representa
`indicator_type`	Tipo de medida, deduzido do código: Percentual (67), Média (15), Taxa (14), Índice (3), Valor monetário (1)
`category_id`	Categoria do indicador. **FK** → CategoriaIndicador

C.7 Medicao (147.829 registros)

Campo	Significado
`measurement_id`	Identificador da medição (chave substituta). **PK**
`SurveyId`	Pesquisa. **FK** → Pesquisa
`country_code`, `region_num_harmonized`	Região. **FK composta** → Regiao
`indicator_code`	Indicador medido. **FK** → Indicador
`value`	Valor observado do indicador
`standard_error`	Erro-padrão da estimativa, quando disponível (pode ser nulo)

C.8 Resumo das funções das tabelas

Tabela	Função principal
Pais	Identifica o país e o continente
Regiao	Identifica a região dentro do país
Pesquisa	Identifica de qual levantamento os dados vieram
ColetaPesquisaRegiao	Registra quais regiões cada pesquisa cobriu e quando
CategoriaIndicador	Organiza indicadores em grupos e áreas temáticas
Indicador	Descreve o que está sendo medido
Medicao	Armazena os valores efetivamente observados